

Laporan Akhir Proyek Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya


Kelas	2024-C
Ketua	Chaesar Giveson (24031554058)
Anggota 1	Sasmita Kusuma Jati (24031554052)
Anggota 2	Nagatan Alief Putra Silahen (24031554086)
URL Github	https://github.com/KsmaJatt/Projek-ML

Informasi Umum Proyek

Judul	Klasifikasi Penyakit Tanaman Menggunakan Perbandingan CNN, EfficientNetB0, dan Hybrid EfficientNetB0-XGBoost pada Dataset PlantVillage untuk Mendukung Ketahanan Pangan
Topik	Pangan
Pilihan Rumusan Masalah	1.3 Dampak Perubahan Iklim dan Rendahnya Adopsi Pertanian Berkelanjutan
Revisi?	Ya / Tidak

Pendahuluan	
Latar belakang (≥ 250 kata)	Sektor pertanian merupakan salah satu pilar utama perekonomian di negara-negara berkembang, termasuk Indonesia. Namun, produktivitas pertanian kerap terganggu oleh serangan penyakit tanaman yang apabila tidak ditangani secara cepat dan tepat dapat menyebabkan kerugian hasil panen yang signifikan. Penyakit pada tanaman seperti tomat, kentang, dan paprika umumnya ditandai dengan perubahan visual pada daun, seperti bercak, perubahan warna, atau pola tertentu yang khas untuk setiap jenis penyakit. Identifikasi penyakit secara konvensional masih sangat bergantung pada keahlian ahli pertanian atau petani berpengalaman, yang ketersediaannya terbatas terutama di daerah terpencil. Perkembangan teknologi kecerdasan buatan, khususnya di bidang computer vision dan deep learning, membuka peluang besar untuk mengotomatisasi proses identifikasi penyakit tanaman melalui analisis citra daun. Convolutional Neural Network (CNN) telah terbukti mampu mengekstrak fitur visual secara hierarkis dari citra, mulai dari tepi dan tekstur sederhana hingga pola kompleks yang membedakan satu jenis penyakit dengan penyakit lainnya. Lebih lanjut, pendekatan transfer learning memungkinkan pemanfaatan pengetahuan yang telah dipelajari model dari dataset berskala besar seperti ImageNet untuk diterapkan pada domain spesifik seperti klasifikasi penyakit tanaman, sehingga mengurangi kebutuhan data latih dan waktu komputasi secara signifikan. Dalam beberapa tahun terakhir, berbagai penelitian telah mengeksplorasi penggunaan arsitektur deep learning untuk klasifikasi penyakit tanaman menggunakan dataset PlantVillage, yang merupakan salah satu dataset citra daun tanaman terbesar dan paling banyak digunakan dalam penelitian di bidang ini. Dataset ini mencakup puluhan kelas penyakit dari berbagai jenis tanaman dan telah menjadi benchmark standar untuk mengevaluasi performa model klasifikasi penyakit tanaman. Meskipun

	demikian, tantangan seperti ketidakseimbangan kelas (class imbalance) dan kemiripan visual antar kelas penyakit masih menjadi permasalahan yang perlu diatasi. Proyek ini mengusulkan perbandingan tiga pendekatan klasifikasi, yaitu CNN sederhana sebagai baseline, EfficientNetB0 dengan transfer learning dari ImageNet, dan model hybrid yang menggabungkan kemampuan ekstraksi fitur EfficientNetB0 dengan kekuatan klasifikasi XGBoost. Selain itu, proyek ini juga mengevaluasi pengaruh penerapan class weighting terhadap performa ketiga model pada kondisi data yang imbalanced, sehingga memberikan gambaran komprehensif mengenai strategi terbaik untuk klasifikasi penyakit tanaman secara otomatis.
Rumusan masalah dan tujuan	<i>Rumusan masalah:</i> 1. Bagaimana cara membangun model klasifikasi penyakit tanaman menggunakan citra daun pada PlantVillage Dataset? 2. Bagaimana performa CNN sederhana, EfficientNetB0, dan Hybrid EfficientNetB0-XGBoost dalam mengklasifikasikan penyakit tanaman? 3. Bagaimana pengaruh penanganan data imbalance terhadap hasil evaluasi model, terutama pada metrik F1-score? <i>Tujuan penelitian:</i> 1. Menyiapkan dataset citra daun tanaman dari PlantVillage Dataset. 2. Melakukan preprocessing data berupa resize gambar, normalisasi, augmentasi data, dan pembagian data latih serta validasi. 3. Melatih tiga model, yaitu CNN sederhana, EfficientNetB0, dan Hybrid EfficientNetB0-XGBoost. 4. Membandingkan hasil model menggunakan Accuracy, Weighted F1, Macro F1, dan Confusion Matrix. 5. Menentukan model yang paling sesuai untuk klasifikasi penyakit tanaman berdasarkan hasil eksperimen.
Metodologi	
Ringkasan dataset	Dataset yang kami gunakan adalah PlantVillage Dataset dari Kaggle. Dataset ini berisi citra daun tanaman yang terdiri dari daun sehat dan daun yang terkena penyakit. Pada proses pengerjaan, kelas yang digunakan berjumlah 15 kelas, yaitu beberapa kelas tanaman paprika, kentang, dan tomat. Contoh kelasnya adalah Pepper bell Bacterial spot, Pepper bell healthy, Potato Early blight, Potato Late blight, Potato healthy, Tomato Bacterial spot, Tomato Early blight, Tomato Late blight, Tomato Leaf Mold, Tomato Septoria leaf spot, Tomato Spider mites, Tomato Target Spot, Tomato Yellow Leaf Curl Virus, Tomato mosaic virus, dan Tomato healthy. Data utama pada dataset ini adalah gambar RGB. Artinya, fitur awalnya bukan berbentuk tabel angka, tetapi citra yang memiliki tiga kanal warna, yaitu Red, Green, dan Blue. Setiap gambar kemudian diubah menjadi ukuran 224 x 224 piksel agar sesuai dengan input model. Label kelas diambil dari nama folder dataset. Dari hasil pembagian data, data validasi berjumlah 4.122 gambar. Jumlah data tiap kelas tidak sepenuhnya seimbang. Contohnya, kelas Tomato Yellow Leaf Curl Virus memiliki 641 data validasi, sedangkan Potato healthy hanya memiliki 30 data validasi. Karena itu, proyek ini menambahkan class weight dan sample weight agar kelas minoritas tetap diperhatikan saat pelatihan model.

Alur penelitian	 <pre> graph TD A[PlantVillage Dataset] --> B[Eksplorasi Data Awal] B --> C[Preprocessing Citra] C --> D[Pembagian Data Train dan Validation] D --> E[Penanganan Imbalance Class Weight / Sample Weight] E --> F[Training Model 1 CNN Sederhana] E --> G[Training Model 2 EfficientNetB0] G --> H[Ekstraksi Fitur EfficientNetB0] H --> I[Training Model 3 XGBoost dari Feature Vector] F --> J[Evaluasi Model] I --> J G --> J J --> K[Perbandingan Hasil dan Kesimpulan] </pre> Gambar 1. Diagram alur Deskripsi langkah: Langkah pertama dataset diambil dari Google Drive setelah sebelumnya disiapkan dari Kaggle. Setelah itu dilakukan pengecekan jumlah kelas dan jumlah gambar per kelas. Tahap berikutnya adalah preprocessing gambar, yaitu mengubah ukuran gambar menjadi 224 x 224 piksel, melakukan normalisasi untuk CNN sederhana, serta memakai preprocess input khusus untuk EfficientNetB0. Data kemudian dibagi menjadi data latih dan data validasi dengan validation split sebesar 20%. Setelah itu, model CNN sederhana dilatih sebagai baseline. Model EfficientNetB0 dilatih dengan pendekatan transfer learning dan dilanjutkan fine-tuning. Pada model hybrid, EfficientNetB0 digunakan sebagai pengambil feature vector, lalu feature vector tersebut dipakai untuk melatih XGBoost. Semua model kemudian dievaluasi dan dibandingkan.
Proses wrangling	Wrangling data yang dilakukan pada proyek ini berfokus pada penyiapan data gambar agar bisa dibaca oleh model. Dataset awal berbentuk folder per kelas, sehingga label dapat diambil langsung dari nama folder. Setiap folder dicek untuk mengetahui jumlah gambar dan memastikan kelas yang tersedia sudah terbaca dengan benar.

	Beberapa proses wrangling yang dilakukan adalah: 1. Menentukan path dataset pada folder PlantVillage. 2. Mengambil daftar nama kelas dari folder dataset. 3. Menghitung jumlah gambar pada setiap kelas. 4. Membuat generator data untuk training dan validation. 5. Mengatur validation generator dengan shuffle=False agar urutan prediksi sesuai dengan label asli. 6. Menambahkan class weight untuk membantu kelas dengan jumlah data kecil. Potongan kode relevan: <pre>class_names = sorted([folder for folder in os.listdir(DATASET_PATH) if os.path.isdir(os.path.join(DATASET_PATH, folder))]) NUM_CLASSES = len(class_names) class_weights_array = compute_class_weight(class_weight='balanced', classes=np.unique(train_gen.classes), y=train_gen.classes) class_weights = dict(enumerate(class_weights_array))</pre> Hasil wrangling menunjukkan bahwa dataset dapat terbaca dengan 15 kelas dan data validasi berjumlah 4.122 gambar. Selain itu, terlihat bahwa distribusi data masih tidak seimbang, sehingga penanganan imbalance memang perlu dilakukan.
Proses rekayasa fitur	Rekayasa fitur pada proyek ini dilakukan dengan dua pendekatan. Pada CNN sederhana, fitur citra dipelajari langsung oleh lapisan konvolusi. Model belajar mengenali pola dasar seperti tepi, warna, tekstur, dan bercak penyakit dari gambar daun. Pendekatan ini dijadikan baseline karena model dilatih dari awal dan hasilnya dapat menjadi pembandingan. Pada EfficientNetB0, rekayasa fitur dilakukan melalui transfer learning. EfficientNetB0 pretrained ImageNet digunakan karena sebelumnya sudah belajar dari banyak gambar umum, sehingga model memiliki kemampuan awal dalam mengenali pola visual. Dalam proyek ini, EfficientNetB0 digunakan untuk mengambil fitur penting dari citra daun. Pada model hybrid, output dari layer Global Average Pooling diberi nama feature_vector dan dijadikan input untuk XGBoost. Potongan kode relevan: <pre>x = layers.GlobalAveragePooling2D(name='feature_vector')(base_model.output) feature_extractor = models.Model(inputs=effnet_model.input, outputs=effnet_model.get_layer('feature_vector').output) X_train_feat = feature_extractor.predict(train_ext)</pre> Selain itu, data augmentation juga digunakan sebagai bentuk rekayasa data. Augmentasi yang digunakan meliputi rotation, zoom, width shift, height shift, dan horizontal flip. Tujuannya agar model tidak hanya menghafal gambar asli, tetapi juga lebih tahan terhadap variasi posisi dan bentuk daun.
Temuan	Temuan utama dari proses data menunjukkan bahwa dataset memiliki distribusi kelas yang tidak seimbang. Beberapa kelas memiliki jumlah gambar yang lebih banyak dibandingkan kelas lainnya. Kondisi ini dapat memengaruhi proses training karena model cenderung lebih mudah mengenali kelas mayoritas, sedangkan kelas minoritas bisa kurang terdeteksi dengan baik. Oleh karena itu, digunakan class weight dan

	<i>sample weight</i> agar model memberikan perhatian yang lebih seimbang terhadap setiap kelas. Setelah penanganan imbalance dilakukan, distribusi prediksi antar kelas menjadi lebih merata namun overall accuracy ketiga model justru mengalami penurunan. Hal ini menunjukkan bahwa transfer learning sudah cukup robust terhadap ketidakseimbangan kelas tanpa teknik balancing tambahan. CNN sederhana masih memiliki performa paling rendah, tetapi tetap berguna sebagai model pembandingan awal. EfficientNetB0 dan Hybrid EfficientNetB0-XGBoost memberikan hasil yang lebih baik karena mampu menangkap fitur visual daun secara lebih kuat. Model hybrid memperoleh accuracy tertinggi, sedangkan EfficientNetB0 memiliki Macro F1 yang nilainya sangat dekat dengan model hybrid. Hal ini menunjukkan bahwa transfer learning cukup membantu dalam klasifikasi citra daun, terutama karena pola penyakit tanaman memiliki bentuk, warna, dan tekstur yang cukup kompleks.
Hasil dan Pembahasan	
Hasil eksplorasi data	Hasil eksplorasi data menunjukkan bahwa dataset yang digunakan terdiri dari 20.638 gambar yang terbagi dalam 15 kelas penyakit dan kondisi sehat pada tanaman paprika, kentang, dan tomat. Data dibagi menjadi 16.516 gambar untuk training (80%) dan 4.122 gambar untuk validasi (20%). Dataset memiliki format folder per kelas sehingga proses pembacaan label dapat dilakukan secara otomatis melalui nama folder. Seluruh citra berbentuk RGB dan diproses pada ukuran 224×224 piksel. Distribusi kelas tidak sepenuhnya seimbang, dengan rasio antara kelas terbesar dan terkecil mencapai sekitar 20:1. Kelas Tomato_Tomato_YellowLeaf_Curl_Virus memiliki jumlah sampel terbesar dengan sekitar 3.189 gambar, sedangkan Potato_healthy menjadi kelas paling sedikit dengan hanya 152 gambar. Ketidakseimbangan ini menjadi alasan mengapa evaluasi tidak cukup hanya menggunakan accuracy. Sebagai contoh, model yang cenderung memprediksi kelas mayoritas dapat mencapai accuracy tinggi namun gagal mengenali kelas minoritas. Oleh karena itu, pada proyek ini digunakan Weighted F1 dan Macro F1 agar performa model pada kelas kecil juga tetap terukur secara adil. Secara visual, penyakit tanaman dapat dibedakan dari pola daun seperti perubahan warna, bercak, tekstur permukaan, dan pola kerusakan. Namun, beberapa kelas penyakit memiliki gejala yang mirip secara visual, terutama pada kelas-kelas penyakit tomat. Hal ini terbukti menjadi tantangan utama dalam proses klasifikasi, di mana Tomato_Early_blight dan Tomato_Target_Spot secara konsisten menjadi kelas dengan F1-Score terendah di semua model eksperimen. Temuan ini menunjukkan bahwa model perlu mengekstrak fitur visual yang lebih diskriminatif untuk membedakan penyakit dengan gejala yang serupa.
Hasil eksperimen	Eksperimen dilakukan dengan tiga model dan dalam dua kondisi: imbalanced (tanpa class weighting) dan balanced (dengan class weighting). Tiga model dilatih dengan konfigurasi yang identik, dengan satu-satunya perbedaan pada penerapan class weighting. Model pertama adalah CNN Balanced sebagai baseline, dilatih dari awal menggunakan beberapa layer Conv2D, MaxPooling, Dropout, dan Dense. Model kedua adalah EfficientNetB0 Balanced yang memanfaatkan transfer learning pretrained ImageNet dilanjutkan dengan fine-tuning. Model ketiga adalah Hybrid EfficientNetB0-XGBoost, di mana EfficientNetB0 digunakan sebagai feature

extractor dan fitur hasil ekstraksi diklasifikasikan menggunakan XGBoost dengan sample weighting.

A. Kondisi Imbalanced

Eksperimen pertama dilakukan pada kondisi imbalanced, yaitu tanpa penerapan class weighting. Hasil evaluasi ketiga model disajikan pada Tabel 1 berikut.

Tabel 1. Hasil Evaluasi Model pada Kondisi Imbalanced

<i>Model</i>	<i>Accuracy</i>	<i>Weight F1</i>	<i>Macro F1</i>
<i>EfficientNetB0</i>	98.50%	0.98	0.99
<i>Hybrid XGBoost</i>	97.67%	0.98	0.97
<i>CNN Sederhana</i>	93.84%	0.94	0.93

CNN Sederhana memiliki performa paling rendah dengan accuracy 93.84% dan Macro F1 0.93. Hal ini wajar karena CNN sederhana dilatih dari awal tanpa pretrained weights, sehingga harus mempelajari seluruh representasi fitur dari nol. Kapasitas model yang terbatas juga menyebabkan kesulitan dalam membedakan kelas dengan kemiripan visual tinggi seperti Tomato_Early_blight dan Tomato_Target_Spot.

EfficientNetB0 mencapai performa terbaik dengan accuracy 98.50% dan Macro F1 tertinggi 0.99. Hampir semua kelas mendapat F1-Score di atas 0.95, termasuk kelas minoritas Potato_healthy yang mendapat F1 sempurna 1.00 meskipun hanya memiliki 30 sampel di data validasi. Hal ini membuktikan bahwa pretrained features dari ImageNet mampu menghasilkan representasi fitur yang kuat bahkan untuk kelas dengan data sangat terbatas (Johnson & Khoshgoftaar, 2019).

Hybrid EfficientNetB0-XGBoost mencapai accuracy 97.67% dan Weighted F1 0.98, sedikit di bawah EfficientNetB0 murni. Hal ini mengindikasikan bahwa classifier head bawaan EfficientNetB0 berupa GlobalAveragePooling dan Dense layer sudah cukup optimal untuk dataset ini, sehingga penggantian dengan XGBoost tidak memberikan peningkatan signifikan pada kondisi imbalanced.

B. Kondisi Balanced

Eksperimen kedua dilakukan pada kondisi balanced dengan menerapkan class weighting pada CNN dan EfficientNetB0, serta sample weighting pada XGBoost. Hasil evaluasi disajikan pada Tabel 2 berikut.

Tabel 2. Hasil Evaluasi Model pada Kondisi Balanced

<i>Model</i>	<i>Accuracy</i>	<i>Weighted F1</i>	<i>Macro F1</i>
<i>Hybrid XGBoost</i>	95.15%	0.95	0.94
<i>EfficientNetB0</i>	94.76%	0.95	0.95

CNN Sederhana	87.77%	0.88	0.85
---------------	--------	------	------


CNN Sederhana pada kondisi balanced mencapai accuracy 87.77% dan Macro F1 0.85, turun signifikan dibandingkan kondisi imbalanced (93.84%). Penurunan ini disebabkan oleh class weighting yang terlalu agresif untuk model dengan kapasitas terbatas, bobot yang sangat besar pada kelas minoritas menyebabkan model mengorbankan performa pada kelas mayoritas yang jumlahnya jauh lebih banyak di data validasi.

EfficientNetB0 Balanced mencapai accuracy 94.76% dengan Macro F1 tertinggi 0.95, menunjukkan distribusi performa yang paling merata antar kelas. Transfer learning dari ImageNet terbukti memberikan representasi fitur yang kuat bahkan setelah class weighting diterapkan.

Hybrid EfficientNetB0-XGBoost mencapai accuracy tertinggi 95.15% dan Weighted F1 tertinggi 0.95, meskipun Macro F1-nya sedikit di bawah EfficientNetB0 (0.94 vs 0.95). Menariknya, pada kondisi balanced Hybrid justru sedikit mengungguli EfficientNetB0 murni, mengindikasikan bahwa XGBoost lebih responsif terhadap sample weighting dibandingkan Dense layer bawaan neural network.

C. Perbandingan Imbalanced vs Balanced

Jika dibandingkan antara kedua kondisi, penerapan class weighting secara umum menurunkan overall accuracy pada semua model. Gambar 2 merangkum perbandingan accuracy antara kondisi imbalanced dan balanced.



Gambar 2. Perbandingan Imbalance vs Balance

Penurunan terbesar terjadi pada CNN Sederhana dengan selisih 6.07%, sementara Hybrid mengalami penurunan paling kecil sebesar 2.52%. Fenomena ini menunjukkan bahwa transfer learning sudah cukup robust terhadap class imbalance tanpa teknik balancing tambahan (Johnson & Khoshgoftaar, 2019; Kornblith et al., 2019). Class weighting yang terlalu agresif justru mengganggu distribusi gradient selama training, terutama pada model dengan kapasitas terbatas seperti CNN Sederhana.

Berdasarkan keseluruhan hasil eksperimen, EfficientNetB0 pada kondisi imbalanced direkomendasikan sebagai model utama dengan accuracy tertinggi 98.50% dan

	Macro F1 0.99. Sementara itu, pada kondisi balanced, Hybrid EfficientNetB0-XGBoost sedikit mengungguli EfficientNetB0 dengan accuracy 95.15% vs 94.76%, menunjukkan bahwa XGBoost sebagai classifier lebih diuntungkan oleh distribusi data yang seimbang dibandingkan Dense layer bawaan neural network.
Kesimpulan dan Saran	
Kesimpulan	<i>Proyek ini berhasil membangun sistem klasifikasi penyakit tanaman menggunakan citra daun pada PlantVillage Dataset dengan membandingkan tiga pendekatan: CNN sederhana sebagai baseline, EfficientNetB0 sebagai model transfer learning, dan Hybrid EfficientNetB0-XGBoost yang menggabungkan ekstraksi fitur deep learning dengan classifier XGBoost.</i> <i>Dari keseluruhan eksperimen, EfficientNetB0 pada kondisi imbalanced mencapai performa terbaik dengan accuracy 98.50% dan Macro F1 0.99, menunjukkan bahwa transfer learning dari ImageNet sangat efektif untuk klasifikasi penyakit tanaman bahkan tanpa teknik penanganan class imbalance tambahan. Pada kondisi balanced, Hybrid EfficientNetB0-XGBoost sedikit mengungguli EfficientNetB0 dengan accuracy 95.15%, mengindikasikan bahwa XGBoost lebih responsif terhadap distribusi data yang seimbang dibandingkan Dense layer bawaan neural network.</i> <i>Temuan menarik dari proyek ini adalah bahwa penerapan class weighting justru menurunkan performa ketiga model, dengan penurunan terbesar pada CNN sederhana (93.84% → 87.77%). Hal ini membuktikan bahwa transfer learning sudah cukup robust terhadap ketidakseimbangan kelas tanpa memerlukan teknik balancing tambahan.</i> <i>Proyek ini dapat berkontribusi sebagai langkah awal dalam membantu deteksi penyakit tanaman secara otomatis. Bagi masyarakat, khususnya petani, pendekatan ini dapat dikembangkan menjadi aplikasi mobile untuk mengenali penyakit dari foto daun secara cepat. Walaupun belum dapat menggantikan ahli pertanian, model ini dapat menjadi alat pendukung agar penyakit tanaman dapat dikenali lebih dini sehingga penanganan dapat dilakukan lebih cepat dan risiko penurunan hasil panen dapat diminimalkan.</i>
Saran	<i>Saran untuk penelitian berikutnya adalah menggunakan dataset yang lebih mendekati kondisi lapangan nyata. PlantVillage memiliki latar belakang gambar yang cukup bersih dan terkontrol, sedangkan kondisi di lapangan biasanya memiliki pencahayaan, sudut kamera, dan latar belakang yang lebih beragam. Karena itu, model perlu diuji kembali pada data yang diambil langsung dari lahan pertanian.</i> <i>Selain itu, jumlah epoch dan proses tuning model dapat ditingkatkan jika sumber daya komputasi lebih memadai. Pada proyek ini epoch dibuat terbatas agar sesuai dengan kemampuan Google Colab. Penelitian berikutnya juga dapat mencoba metode lain seperti ResNet, MobileNet, atau Vision Transformer sebagai pembanding. Untuk pengembangan lebih lanjut, model dapat dibuat dalam bentuk aplikasi sederhana agar pengguna bisa mengunggah gambar daun dan langsung mendapatkan prediksi penyakit.</i>
Daftar Pustaka	
Daftar Pustaka	1. https://doi.org/10.1016/j.compag.2021.106253 (Computers and Electronics in Agriculture, 2021)

	2. https://doi.org/10.1016/j.eswa.2022.116791 (<i>Expert Systems with Applications</i>, 2022) 3. https://doi.org/10.1109/ACCESS.2020.3028901 (<i>IEEE Access</i>, 2020) 4. https://doi.org/10.1016/j.infsof.2023.107128 (<i>Information and Software Technology</i>, 2023) 5. https://doi.org/10.1016/j.compag.2020.105824 (<i>Computers and Electronics in Agriculture</i>, 2020) 6. https://doi.org/10.1109/ACCESS.2021.3119655 7. https://doi.org/10.1109/ACCESS.2022.3165583
--	---