

Proposal Proyek Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-C
Ketua	Chaesar Giveson (24031554058)
Anggota 1	Sasmita Kusuma Jati (24031554052)
Anggota 2	Nagatan Alief Putra Silahen (24031554086)
URL Github	https://github.com/KsmaJatt/Projek-ML

Informasi Umum Proyek

Judul	Klasifikasi Penyakit Tanaman Menggunakan Perbandingan CNN, EfficientNetB0, dan Hybrid EfficientNetB0-XGBoost pada Dataset PlantVillage untuk Mendukung Ketahanan Pangan
Topik	Pangan
Pilihan Rumusan Masalah	1.3 Dampak Perubahan Iklim dan Rendahnya Adopsi Pertanian Berkelanjutan
Revisi?	Ya

Deskripsi Rumusan masalah	Penyakit tanaman pangan secara konsisten menjadi penyebab gagal panen di Indonesia. Tanaman seperti padi, jagung, dan tomat rentan terserang penyakit yang sering baru terdeteksi setelah kerusakan meluas. Estimasi kerugian akibat penyakit tanaman berkisar 20–40% dari total produksi per tahun. Deteksi manual oleh petani atau ahli agronomi tidak bisa mengikuti skala dan kecepatan yang dibutuhkan. Pendekatan berbasis citra daun dengan machine learning menawarkan solusi, tapi tetap ada tantangan nyata: variasi pencahayaan di lapangan, gejala antar penyakit yang mirip, dan keterbatasan data berlabel. Proyek ini mengusulkan pendekatan hybrid yang menggabungkan CNN sebagai feature extractor dengan XGBoost sebagai classifier, dengan harapan mendapatkan akurasi lebih baik dari masing-masing pendekatan secara terpisah.
Tujuan penelitian (Objectives)	1. Mengunduh dan mempersiapkan PlantVillage Dataset dari Kaggle yang berisi citra daun tanaman sehat dan daun tanaman berpenyakit. 2. Melakukan preprocessing citra, seperti resize gambar, normalisasi nilai piksel, label encoding, train-test split, dan augmentasi data. 3. Membangun model CNN sederhana sebagai baseline untuk melihat performa awal klasifikasi penyakit tanaman. 4. Membangun model transfer learning menggunakan EfficientNetB0 pretrained ImageNet sebagai pembanding karena model ini mampu mengekstraksi fitur visual gambar dengan lebih efisien. 5. Membangun model hybrid EfficientNetB0-XGBoost, yaitu EfficientNetB0 digunakan untuk mengambil fitur gambar, sedangkan XGBoost digunakan sebagai classifier utama. 6. Membandingkan performa tiga model, yaitu CNN sederhana, EfficientNetB0, dan Hybrid EfficientNetB0-XGBoost.

	7. Mengevaluasi model menggunakan Accuracy, Precision, Recall, F1-Score, dan Confusion Matrix.
Referensi penelitian	1. https://doi.org/10.1016/j.compag.2021.106253 (Computers and Electronics in Agriculture, 2021) 2. https://doi.org/10.1016/j.eswa.2022.116791 (Expert Systems with Applications, 2022) 3. https://doi.org/10.1109/ACCESS.2020.3028901 (IEEE Access, 2020) 4. https://doi.org/10.1016/j.infsof.2023.107128 (Information and Software Technology, 2023) 5. https://doi.org/10.1016/j.compag.2020.105824 (Computers and Electronics in Agriculture, 2020)

Informasi Detil Dataset

Sumber dataset	https://www.kaggle.com/datasets/emmarex/plantdisease
Deskripsi awal fitur dataset	1. image Atribut ini merupakan data utama dalam dataset berupa citra daun tanaman yang diambil dalam format RGB. Semua foto direpresentasikan dalam format RGB dan dinormalisasi untuk menyesuaikan proses deep learning. Tipe data atribut ini adalah array tiga dimensi ($H \times W \times 3$) yang merepresentasikan tinggi, lebar, dan tiga kanal warna citra. 2. image_id Atribut ini merupakan identifikasi unik untuk setiap file gambar dalam dataset, biasanya berupa nama file seperti 0a1e8d5e-cc84.jpg yang ditetapkan secara otomatis saat dataset dikompilasi. Tipe data atribut ini adalah String atau Categorical yang berfungsi sebagai kunci primer untuk membedakan satu sampel citra dengan sampel lainnya. 3. label / class Setiap direktori dalam dataset menyertakan label spesies dan status kesehatan citra, misalnya direktori bernama Tomato_Late_blight hanya berisi gambar daun tomat dengan gejala penyakit hawar daun, sedangkan Apple_Healthy berisi gambar daun apel yang sehat. Atribut ini bertipe Categorical dengan total 38 kelas unik yang menjadi target klasifikasi dalam penelitian. 4. plant_species Dataset ini mencakup 14 spesies tanaman: Apple, Blueberry, Cherry, Corn, Grape, Orange, Peach, Bell Pepper, Potato, Raspberry, Soybean, Squash, Strawberry, dan Tomato. Atribut ini bertipe Categorical dengan 14 kategori dan berfungsi sebagai informasi taksonomi dasar sebelum proses klasifikasi penyakit dilakukan. 5. disease_name Atribut ini menyimpan nama spesifik penyakit yang menginfeksi daun tanaman, atau keterangan "Healthy" apabila daun tidak menunjukkan gejala infeksi apapun. Tipe data atribut ini adalah Categorical yang nilainya diturunkan langsung dari penamaan folder dalam struktur direktori dataset.

	6. disease_type Dataset ini mencakup 17 penyakit jamur (fungal), 4 penyakit bakteri (bacterial), 2 penyakit mold (oomycete), 2 penyakit virus (viral), dan 1 penyakit yang disebabkan oleh tungau (mite). Atribut ini bertipe Categorical dan penting untuk analisis distribusi jenis patogen dalam kerangka penelitian ketahanan pangan. 7. health_status Atribut ini merepresentasikan kondisi daun secara biner, yaitu apakah daun tergolong sehat (Healthy) atau berpenyakit (Diseased), dan diturunkan dari atribut label. Tipe datanya adalah Binary atau Categorical yang berguna untuk analisis ketidakseimbangan kelas sebelum pelatihan model dilakukan. 8. image_resolution Dataset menggunakan resolusi gambar seragam sebesar 224×224 piksel untuk memastikan konsistensi dimensi input pada seluruh arsitektur deep learning yang digunakan. Tipe data atribut ini adalah Integer yang merepresentasikan jumlah piksel pada sumbu horizontal dan vertikal citra. 9. color_channel Atribut ini merepresentasikan tiga saluran warna pada setiap citra, yaitu Red (R), Green (G), dan Blue (B), dengan nilai intensitas piksel berkisar antara 0 hingga 255 per kanal. Tipe data atribut ini adalah Integer yang menjadi dasar ekstraksi fitur visual oleh lapisan konvolusi pada arsitektur CNN. 10. background_type PlantVillage menggunakan lingkungan terkontrol untuk pengambilan gambar, di mana setiap gambar diambil dengan latar belakang bersih, sudut terkontrol, dan arah kamera yang konsisten. Atribut ini bertipe Categorical dan perlu diperhatikan dalam konteks generalisasi model, mengingat kondisi lapangan nyata umumnya tidak memiliki latar belakang yang terkontrol.
Aspek khusus dari dataset	Dataset yang digunakan berupa citra daun tanaman, sehingga data utamanya bukan berbentuk tabel angka, tetapi gambar RGB. Data ini tidak termasuk data sparse karena setiap gambar memiliki informasi piksel yang lengkap pada setiap kanal warna. Dataset PlantVillage memiliki beberapa kelas tanaman dan penyakit. Distribusi antar kelas perlu diperiksa terlebih dahulu karena kemungkinan jumlah gambar pada setiap kelas tidak sama. Jika ditemukan ketidakseimbangan kelas, maka dapat digunakan data augmentation dan evaluasi dengan Precision, Recall, serta F1-Score agar penilaian model tidak hanya bergantung pada Accuracy. Outlier pada dataset dapat berupa gambar yang buram, terlalu terang, terlalu gelap, atau memiliki daun yang tidak terlihat jelas. Gambar seperti ini perlu diperiksa pada tahap eksplorasi data. Jika jumlahnya sedikit dan masih bisa dikenali, gambar tetap dapat digunakan agar model lebih tahan terhadap variasi kondisi gambar. Selain itu, dataset PlantVillage umumnya memiliki latar belakang gambar yang cukup bersih dan terkontrol. Hal ini memudahkan model dalam belajar, tetapi juga perlu diperhatikan karena kondisi gambar di lapangan nyata bisa lebih bervariasi.

Rencana Metode

Teknik yang digunakan	1. CNN sederhana sebagai model baseline untuk melihat performa dasar klasifikasi citra daun. 2. Transfer Learning menggunakan EfficientNetB0 pretrained ImageNet sebagai model pembandingan yang lebih kuat dan efisien. 3. Hybrid EfficientNetB0-XGBoost sebagai model utama, dengan EfficientNetB0 untuk ekstraksi fitur gambar dan XGBoost sebagai classifier. 4. Augmentasi data seperti rotation, zoom, dan horizontal flip untuk menambah variasi gambar pada data latih. 5. Evaluasi dan perbandingan performa menggunakan Accuracy, Precision, Recall, F1-Score, dan Confusion Matrix.
Alasan pemilihan teknik/algoritma	CNN sederhana dipilih sebagai baseline agar hasil model utama dapat dibandingkan dengan model dasar yang dilatih dari awal. EfficientNetB0 dipilih karena termasuk arsitektur CNN yang ringan dan efisien, tetapi tetap mampu mengambil fitur visual penting dari gambar daun, seperti warna, tekstur, bercak, dan pola kerusakan. XGBoost dipilih karena termasuk metode ensemble machine learning yang kuat untuk klasifikasi. Pada model hybrid, EfficientNetB0 digunakan untuk mengambil feature vector dari gambar, kemudian XGBoost digunakan untuk menentukan kelas penyakit tanaman. Kombinasi ini dipilih karena CNN/ EfficientNetB0 kuat dalam memahami pola visual, sedangkan XGBoost kuat dalam proses klasifikasi akhir. Dengan menggunakan tiga model, penelitian ini tidak hanya membuat satu model, tetapi juga membandingkan mana pendekatan yang memberikan hasil terbaik pada PlantVillage Dataset.
Langkah-langkah umum pengerjaan	1. Mengunduh PlantVillage Dataset dari Kaggle dan menyusun struktur folder dataset. 2. Melakukan eksplorasi data, seperti melihat jumlah kelas, jumlah gambar tiap kelas, dan contoh gambar daun. 3. Melakukan preprocessing citra, yaitu resize gambar, normalisasi nilai piksel, label encoding, train-test split, dan augmentasi data. 4. Melatih CNN sederhana sebagai model baseline. 5. Melatih EfficientNetB0 pretrained ImageNet sebagai model transfer learning. 6. Mengekstrak feature vector dari EfficientNetB0, lalu melatih XGBoost sebagai classifier pada model hybrid. 7. Mengevaluasi setiap model menggunakan Accuracy, Precision, Recall, F1-Score, dan Confusion Matrix. 8. Membandingkan hasil dua model untuk menentukan model yang paling baik dalam klasifikasi penyakit tanaman.